

IDB SS23 Solutions & Notes

Igor Dimitrov

Jacob Rose

Jonathan Barthelmes

Table of contents

IDB SS 23 Loesungen & Notizen	4
I Loesungen	5
1 Grundlagen der Relationalen Algebra	6
1.1 Grundlagen der Logik	6
1.2 Relationale Algebra	7
1.3 Datenmanagementsysteme	8
1.4 Feedback	9
2 Relationale Algebra und SQL	11
2.1 Relationale Algebra - Fortsetzung	11
2.2 SQL-Anfragen	11
2.3 Entsprechungen in SQL und der relationalen Algebra	13
2.4 ER-Modell	13
2.5 Feedback	15
3 ER-Modellierung	16
3.1 ER-Modellierung: Staedte	16
3.2 ER-Modellierung: Filmstudio-Datenbank	16
3.3 Feedback	18
4 Uebersetzung ER-Schema in Relationenschemata	19
4.1 Uebersetzung eines ER-Schemas	19
4.2 Uebersetzung eines ER-Schemas mit Hierarchien	19
4.3 Feedback	20
5 SQL-Anfragen	21
5.1 Grundlegende Anfragen	21
5.2 String-Funktionen	23
5.3 Exists-Operatoren	25
5.4 Aggregat-Funktionen und Gruppierung	27
5.5 Feedback	29

6	Rekursion, Relationale Algebra und SQL	30
6.1	Data Definition Language (DDL) und Rekursion in SQL	30
6.2	Relationale Algebra und SQL	32
6.3	Regulaere Ausdruecke in SQL	34
6.4	Feedback	35
7	SQL und Anfragesprachen	36
7.1	Fortgeschrittene SQL-Anfragen	36
7.2	Relationale Algebra und Tupelkalkuel	38
7.3	Feedback	39
8	Physische Datenorganisation und Baeume	40
8.1	Seiten und Saetze	40
8.2	B-Baeume	42
8.3	B ⁺ -Baeume	42
8.4	Feedback	43
9	Hashing, Indexzugriffe und Sortierung	45
9.1	Erweiterbares Hashing	45
9.2	Sortierung	46
9.3	Zugriffsmethoden	47
9.4	Feedback	47
10	Anfragebearbeitung	48
10.1	Join-Strategien	48
10.2	Algebraische Optimierung	49
10.3	Feedback	52
II	Notes	54

IDB SS 23 Loesungen & Notizen

IDB SS 23 Loesungen & Notizen

Part I

Loesungen

1 Grundlagen der Relationalen Algebra

1.1 Grundlagen der Logik

a)

1. Wenn zwei Tiere im selben Lebensraum leben, essen sie auch das selbe.

falsch: t_1 (Gepard) und t_9 (Uganda-Grasantilope) haben den gleichen lebensraum ``Regenwald'' aber andere Ernaehrungen; Karnivore und bzw. Herbivore.

erfuellbar: Jede Datenbank, die ein einziges Tier enthaelt erfuehlt diese Aussage automatisch.

2. Fuer jedes Zootier existier ein anderes Zootier, welches entweder die selbe Nahrung isst oder im selben Lebensraum lebt. **wahr**

3. Es existieren drei Zootiere, so dass erstes und zweites ,sowie zweites und drittes den gleichen Lebensraum teilen aber erstes und drittes nicht.

falsch und nicht erfuellbar: $l(x, y)$ ist eine Aequivalenzrelation. Somit gilt Transitivitaet: $l(x, y) \wedge l(y, z) \rightarrow l(x, z)$

4. Es gibt keine zwei unterschiedliche Tiere, die sowohl der gleichen Familie zugehoerig sind als auch den gleichen Lebensraum teilen.

falsch: t_6 und t_{10} sind beide Sakiaffen mit dem Lebensraum Regenwald.

erfuellbar: Jede Datenbank mit einem einzigen Element efuehlt diese Aussage automatisch.

b)

1. $\forall x \in T \exists y \in T : x \neq y \wedge fam(x, y) \wedge \neg ls(x, y)$
2. $\forall x \in T \forall y \in T : fam(x, y) \wedge le(x, y) \wedge er(x, y) \rightarrow x = y$
3. $\forall x \in T \forall y \in T : fam(x, y) \rightarrow er(x, y)$

1.2 Relationale Algebra

1. Gebe die Modelle von Flugzeugen, die so heissen, wie einer aus dem Personal.

Modell
Quack

2. Gebe die crew ID der Mitarbeiter, die nicht an den afugelisteten Fluegen beteiligt sind.

cid
c090

3. Gebe die Flugnummer der Fluege, die in Deutschland starten.

Flugnr
DB2013
DB2341

4. Gebe alle Modelle aus, fuer die eine Crew-Mitglied zugelassen ist.

Zulassung
A320
B787
A380
A340
B747

5. Gebe alle Namen von Piloten aus, die fuer eine Maschine zugelassen sind mit Reichweite ≤ 10000 .

Name
Pan
Schmitt

6. Gebe Start, Ziel und Modell fuer alle Modelle aus, die ungeeignet fuer einen Flug sind, weil sie die Strecke nicht fliegen koennen.

Start	Ziel	Modell
FRA	JFK	A320
JFK	FRA	A320
CDG	LAX	A320

7. Waehle aus Fluegen die gleichen Flugnummern, die an unterschiedlichen Tagen fliegen, d.h. gebe Flugnummern der Fluegen, die Rundfahrten sind.

Flugnr
DB2013

8. Gebe die Laender aus, aus denen keine Flugzeuge starten.

Land
Deutschland

1.3 Datenmanagementsysteme

- a) XML und HTML basieren sich beide auf **SGML** - eine Metasprache, mit deren Hilfe man verschiedene Markup-sprachen fuer Dokumente definieren kann.

XML ist eine erweiterbare Markup-sprache, die zur Darstellung & Speicherung hierarchisch strukturierter Daten und zur Definition & Entwicklung neuer Markup-sprachen verwendet wird. XML Dokumente haben eine Baumstruktur und bestehen aus **Elemente**, die durch **Tags** Ausgezeichnet werden. XML hat keinen vordefinierten Satz von Tags, wobei die genaue Struktur eines XML-Dokuments durch den **Dokumenttypdefinition** festgelegt werden kann.

HTML beschreibt die semantische Struktur und Formattierung der Inhalte von Webseiten und war urspruenglich eine Anwendung von SGML. Im Gegensatz zu XML hat HTML einen festen Satz von Tags, die fuer die Auszeichnung der Elementen verwendet werden koennen. Streng genommen ist HTML kein XML hat aber im wesentlichen die gleiche Struktur wie ein XML-Dokument. (Hierarchische Baumstruktur, Elemente, Tags, DOM).

Fuer XML gibt es viele standarte Werkzeuge, die XML Dokumente auf Wohlgeformtheit pruefen und programmatisch verarbeiten koennen, z.B. wie

- XML-Prozessor/Parser,
- **XQuery**: die standard XML Abfrage- und Transformationssprache,
- **XPath**: Untersprache von XQuery, die XQuery unterstützt,
- **XSLT**: Sprache die speziell dazu geeignet ist, XML Dokumente in andere Formate umzuwandeln.

Diese Tools stehen in XML Datenbanken zur Verfügung und XML Datenbanken sind für die Arbeit mit XML-Dokumenten optimiert. Somit können HTML-Dokumente mit den etablierten zahlreichen XML Tools optimal verarbeitet werden, wenn sie in einer XML Datenbank gespeichert werden.

Ein weiterer Vorteil ist, dass eine XML-Datenbank kein oder nur ein vereinfachtes Datenschema (Beziehungsschema/Tabellen) braucht, da die Daten schon durch das Dateiformat strukturiert werden. Bei einer relationalen Datenbank muss das Schema explizit definiert werden. D.h. um ein HTML-Dokument in einer RDB zu speichern, oder um ein Dokument aus einer RDB zu exportieren muss jedes mal eine Transformation zwischen der HTML-Darstellung und relationalen Darstellung des Dokuments durchgeführt werden. Weiterhin funktioniert die Abbildung zwischen den Dokument-orientierten und relationalen Modellen nicht immer gut und wird als **object-relational impedance mismatch** bezeichnet.

b) **Vorteile:**

- Man benötigt kein vordefiniertes Schema
- Kommt gut mit vielen Lese- und Schreibzugriffen zurecht.

Nachteile:

- Geringe Konsistenz/Gültigkeit der Daten.
- Weil es weniger Einschränkungen gibt, können die Abfragen nicht so gut optimiert werden wie bei den relationalen DBen.

1.4 Feedback

Rose, Dimitrov, Barthelmes

Aufgabe 1:

- a) Ja, technisch gesehen erfüllen Datenbanken, die nur ein Tier enthalten, die 1 und 4, wäre halt nur besser gewesen, wenn ihr ein "normales" Beispiel mit mindestens 2 Tieren gewählt hättet :D

9/9 Punkte

Aufgabe 2:

1. Es wird das MODELL gesucht, nicht der NAME :D Also A380
5. Nicht ganz, es sind eher alle Personen, die nicht für ein
↪ Flugzeug mit Reichweite >10000 zugelassen sind.
6. "Ungeeignet"? Habt ihr nie von technischen Zwischenstopps gehört?
↪ :p
7. Nicht unbedingt Rundfahrten
8. "... Länder aus, die einen Flughafen haben, aus dem..."

8/11 Punkte

Aufgabe 3:

Habt ihr ChatGPT verwendet? Das sieht sehr nach ChatGPT aus...

4/4 Punkte

Insgesamt 21/24 Punkte

2 Relationale Algebra und SQL

2.1 Relationale Algebra - Fortsetzung

1. $\pi_{pid, Name}(\sigma_{\text{Rolle}="Pilot", \text{Reichweite} \geq 15000}(\text{Personal} \bowtie \text{Zulassung} \bowtie \text{Modell}))$
2. $\pi_{Name}(\sigma_{\text{Land}='USA'}(\beta_{\text{Code} \leftarrow \text{Ziel}}(\text{Flug}) \bowtie \text{Flughafen} \bowtie \text{Flugzeug}))$
3. $\pi_{\text{Code}, \text{Land}}\left(\sigma_{\text{Name}='F. Kohl'}\left(\text{Flugzeug} \bowtie \left(\beta_{\text{Code} \leftarrow \text{Start}}(\pi_{\text{Start}, \text{fid}}(\text{Flug})) \cup \beta_{\text{Code} \leftarrow \text{Ziel}}(\pi_{\text{Ziel}, \text{fid}}(\text{Flug}))\right)\right)\right)$
4. $\pi_{pid, Name}(\text{Personal}) - \pi_{pid, Name}(\text{Personal} \bowtie \text{Crew} \bowtie \sigma_{\text{Datum} < 07.04.2013}(\text{Flug}))$

2.2 SQL-Anfragen

1. SQL:

```
select distinct C from R3
```

Ergebniss:

```
{C: 7},
{C: 8}}
```

2. SQL:

```
select distinct * from R2
where B = rot
```

Ergebniss::

```
{B: rot, C: 9}
{B: blau, C: 8}}
```

3. SQL:

```
select distinct * from R2
intersect
select distinct * from R3;
```

Ergebniss:

```
{{B: blau}, {C: 7}}
```

4. SQL:

```
select * from R2
union
select * from R3
```

Ergebniss:

```
{{B: blau, C: 7},
{B: rot, C: 8},
{B: rot, C: 9},
{B: gruen, C: 8},
{B: gelb, C: 7}}
```

5. SQL:

```
select * from R3 except (
    select * from R2
);
```

Ergebniss:

```
{{B: gruen, C: 8},
{B: gelb, C: 7}}
```

6. SQL:

```
select distinct * from
R1 natural jo R2
```

Ergebniss:

```
{{A: q, B: rot, C: 8},
{A: q, B: rot, C: 9}}
```

7. SQL:

```
select distinct * from  
R1, R2
```

Ergebniss:

```
{A: q, R1.B: rot,   R2.B: blau,  C: 7 },  
{A: q, R1.B: rot,   R2.B: gruen, C: 8},  
{A: q, R1.B: rot,   R2.B: gelb,  C: 7},  
{A: r, R1.B: gruen, R2.B: gelb,  C: 7},  
{A: r, R1.B: gruen, R2.B: gruen, C: 8},  
{A: r, R1.B: gruen, R2.B: gelb,  C: 7}}
```

2.3 Entsprechungen in SQL und der relationalen Algebra

1. Die Anfragen entsprechen sich liefern jedoch nicht das gleiche Ergebniss, da der SQL-Ausdruck Duplikate zulaesst, waehrend bei der relationalen Abfrage die Duplikate entfernt werden.
2.
 1. Die SQL-Anfrage liefert die **Bezeichnung** der Modelle, die nach Flughafen 'CDG' fliegen/geflogen haben.
 2. Der relationale Ausdruck liefert die Sitzplatzkapazitaeten der selben Modelle aus der SQL-Anfrage.


Somit sind die Ausdruecke nicht Aequivalent und sie entsprechen sich nicht.

3.
 1. Die erste SQL-Anfrage gibt die ID's der Co-Pilote und die Bezeichnungen der Modelle aus, dafuer sie zugelassen sind.
 2. Die zweite SQL-Anfrage gibt genau das gleiche Ergebniss wie die erste Anfrage. Man beachte, dass natural join in SQL immer von einem Kreuzprodukt und Selektionsoperationen simuliert werden kann.

Somit sind die beiden Anfragen Aequivalent

2.4 ER-Modell

See the diagrams



*Autor kann beliebig viele Buecher schreiben.
(Moeglicherweise hat ein Autor kein Buch geschrieben)*


*Ein Buch muss mindestens von einem Autor verfasst werden.
Ein buch kann von mehreren Autoren mitverfasst werden.*

Figure 2.1: Zeile 1

*Ein Verlag kann beliebig viel Buecher drucken.
Ein Verlag kann noch keine Buecher gedruckt haben - z.B ein neu gegruendeter Verlag
Ein Verlag hat einen Name und seinen Sitz in einem Land.*

*Ein Buch wird mindestens von einem Verlag gedruckt,
kann aber von mehreren Verlage gedruckt werden - z.B die Bibel.*

Figure 2.2: Zeile 2




*Ein Buecherladen hat einen beliebig grossen Katalog von Buecher, die im Laden verkauft werden.
Der Katalog kann leer sein.
Ein Buecherladen wird Anhand einer Kombination seiner Adresse und seines Names unterschieden.
Ein Buch kann in beliebig vielen oder in keinen Laden verkauft werden.*

Ein Buch gehoert zu mindestens einer Genre.

Es kann beliebig viele Bucher zu einer Genre geben.

Figure 2.4: Zeile 4

Figure 2.3: Zeile 3



*Ein Kunde kann beliebig viele Buecher kaufen, muss aber zumindest ein Buch gekauft haben,
um in Datenbank als 'Kunde' eingetragen zu werden.*

Ein Buch kann von beliebig vielen Kunden gekauft werden.

Figure 2.5: Zeile 5

2.5 Feedback

Zur Aufgabe 1.

1. Richtig, wenn auch $>$ statt \geq gemeint
2. Richtig 3. Sollte passen 4. Richtig

Zur Aufgabe 2:

1. Richtig 2. Ergebnis: Wieso B: Blau wenn ihr nach rot selektiert \Rightarrow -
 \hookrightarrow 0.25 P.
- 3.-7. Richtig

Zur Aufgabe 3:

1. Richtig unter der Annahme, dass Tabelle mehr als die abgedruckten
 \hookrightarrow Beispieldaten enthält (Stichwort Distinct)
2. Ebenfalls richtig
3. Dito

Zur Aufgab 4:

1. Richtig 2. Verlage sollen laut ML bitte mindestens ein Buch verlegen
 \hookrightarrow \Rightarrow - 0.25P. 3. Laut ML bitte $[1, *]$ \Rightarrow - 0.25 P.
4. Richtig 5. Ebenfalls

3 ER-Modellierung

3.1 ER-Modellierung: Staedte

ER-Schema: Stadt

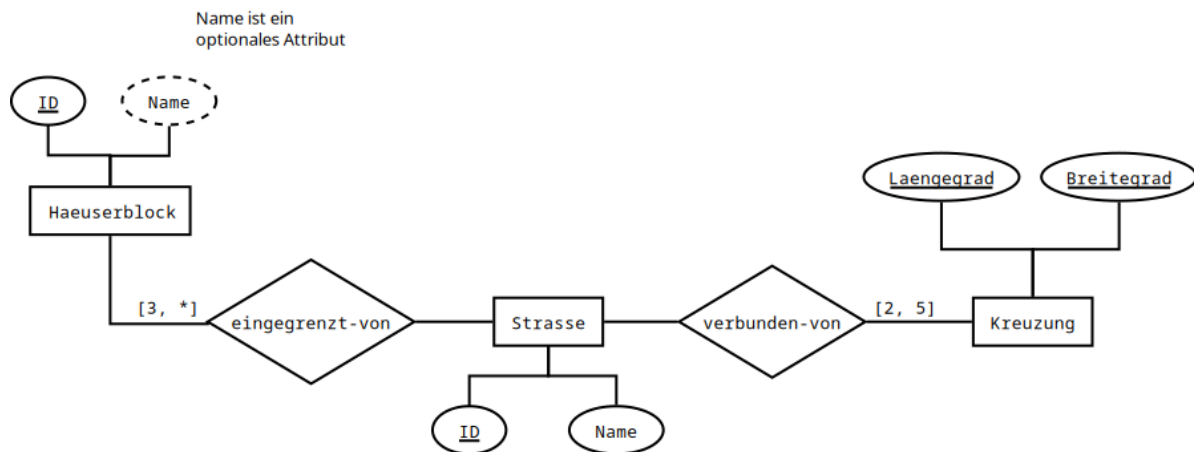


Figure 3.1: ER-Schema: Stadt

3.2 ER-Modellierung: Filmstudio-Datenbank

1. ER-Schema Figure [3.2](#)

2. *Integriteatsbedingungen*

1. i.A. koennen die Wertebereiche der Attribute im ER-Diagram nicht spezifiziert werden, z.B. wie
 1. Erscheinungsjahr eines Films darf nicht in der Zukunft liegen oder ein sehr altes Datum wie 1776 sein.
 2. Gage eines Regissuers muss $> 30,000$ € sein
 3. Globale Bedingungen wie z.B. **Gesamtgehalt** aus mehreren Filmen darf nie ueber 1000000 € sein koennen auch nicht spezifiziert werden.

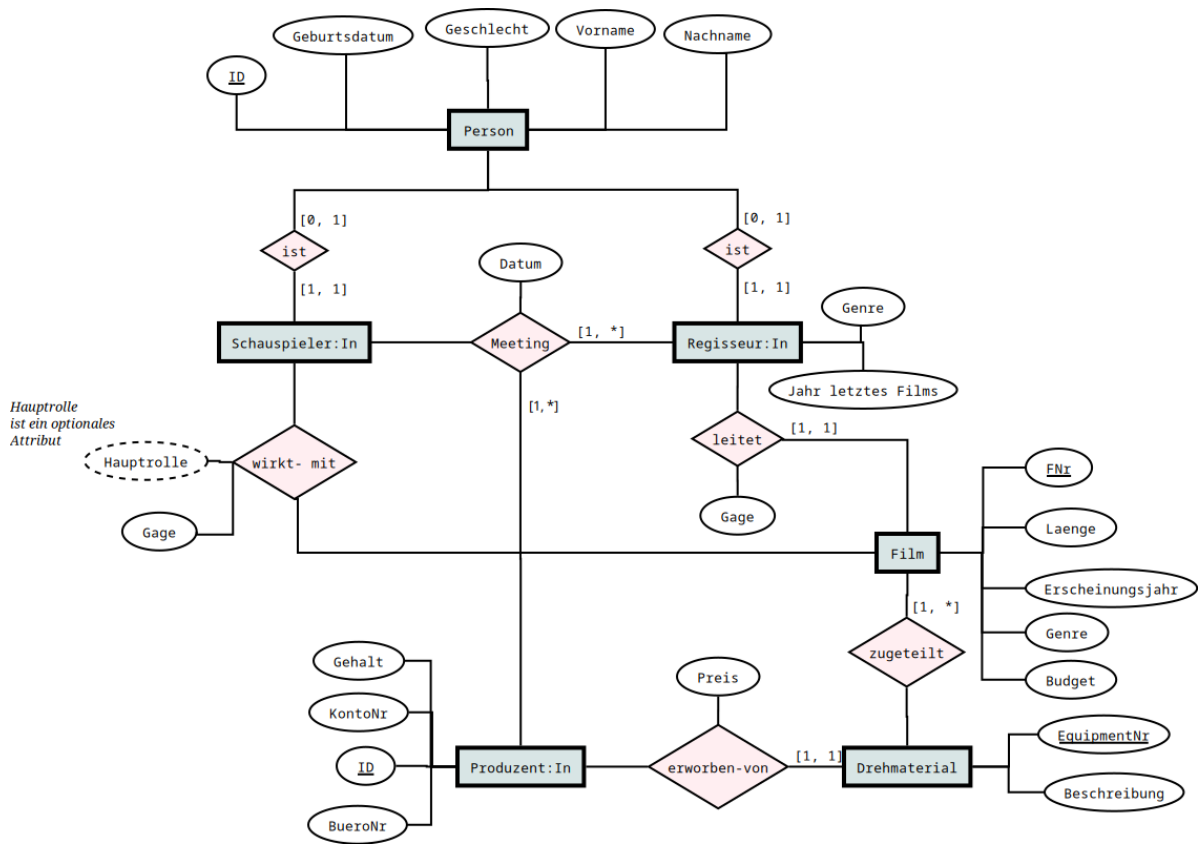



Figure 3.2: ER-Schema: NetMovie DB

2. In der Spezifikation heisst es, dass in jedem Film genau zwei Hauptrollen gibt. In unserem ER-Schema haben wir Hauptrolle als eine optionale Attribute des Beziehungstyps ``wirkt-mit'' modelliert. Diese Kardinalitaet kann somit nicht in unsrem ER-Schema bestimmt werden.

3. Alternative Modellierungen

- Gage als Attribute der Entitaet **Film** modellieren.
- Eine neue Entitaet ``**Genre**'' einfuehren, und ``arbeitet-in'' Beziehungen zwischen Regisseur-Genre, und zwischen Schauspieler-Genre modellieren:



3.3 Feedback

Punkte: 29.0/30

4 Uebersetzung ER-Schema in Relationenschemata

4.1 Uebersetzung eines ER-Schemas

- Adresse(Ad_ID, PLZ, Stadt, Strasse, Hausnr)
- MusikerIn(M_ID, Name, Geb_Datum, Ad_ID → Adresse)
- Instrument(Name, Stimmung)
- spielt(M_ID→MusikerIn, (Name, Stimmung)→Instrument, bevorzugt)
- Musikstueck(MS_ID, Titel, Laenge, M_ID→MusikerIn)
- Album(A_ID, Titel, Release_Datum, Preis, Tracks, M_ID→MusikerIn)
- erscheint(M_ID→Musikstueck, A_ID→Album, TrackNr)
- spielt_mit(M_ID→MusikerIn, MS_ID→Musikstueck)

4.2 Uebersetzung eines ER-Schemas mit Hierarchien

1. *Relationales Schema*

- Personal(Pers_ID, GebDat, Name, Vorname)
- MitarbeiterIn(Pers_ID→Personal, Bonus)
- KundIn(KundenID→Personal, Branche)
- ManagerIn(Pers_ID→MitarbeiterIn, Sektion)
- ProgrammiererIn(Pers_ID→MitarbeiterIn, Abschluss)
- Programmiersprache(ProgSP)
- kann(ProgSP→Programmiersprache, Pers_ID→ProgrammiererIn, level)

2. *Weitere Methoden fuer is-a:*

- i)
 - **Vorteil:** Vermeidung der Redundanz und moeglichen Inkonsistenzen, die dadurch entstehen koennen.
 - **Nachteil:** Erhoehter Rechenaufwand durch Zugriff auf Attribute der Oberentitaet nur mit Join.
- ii)
 - **Vorteil:** Vermindertee Rechenaufwand durch direkten Zugriff auf Attribute ueber Tupel einziger Relation.

- **Nachteil:** Redundante Speicherung der gleichen Informationen.
- iii) • **Vorteil:** Vermindernde Komplexität des Datenbanks durch kleinere Anzahl von Relationen (eine Relation statt zwei oder drei)
- **Nachteil:** Mögliche Inkonsistenzen durch den vielen Nullwerten, die von dem Nutzer bei Insertoperationen explizit als null gesetzt werden müssen.

4.3 Feedback

Punkte: 26/28

Zur Aufgabe 1:

Bei Fremdschlüsselverweisen auf Relationen (z.B. in MusikerIn bitte
↔ sowas wie wohnt->Adresse) schreiben => -2P.

Rest der 1. passt.

Zur Aufgabe 2:

Zur 1:

Passt alles.

Zur 2:

Ebenfalls.

5 SQL-Anfragen

5.1 Grundlegende Anfragen

1.

```
select real_name, created_at
from twitter_user tu
where typ = 'lobby' and
date(created_at) < timestamp '2009-06-30'
order by created_at
```

Table 5.1: A 1.1

real_name	created_at
Sascha Lobo	2007-05-08 21:10:26
netzpolitik	2007-10-24 14:34:50
Ulrich Müller	2009-01-07 14:50:51
Mehr Demokratie e.V.	2009-04-02 19:36:30
CCC Updates	2009-04-16 14:04:59
abgeordnetenwatch.de	2009-04-25 04:14:23
LobbyControl	2009-05-07 14:48:55

2.

```
select twitter_name, like_count
from twitter_user tu , tweet t
where tu.id = t.author_id
and t.like_count between 22000 and 25000;
```

Table 5.2: A 1.2

twitter_name	like_count
n_roettgen	22974
n_roettgen	24329
SWagenknecht	24656
MAStrackZi	22713

3.

```

select distinct h.txt
from
    twitter_user tu ,
    tweet t ,
    hashtag_posting hp ,
    hashtag h
where tu.id = t.author_id and
    t.id = hp.tweet_id and
    hp.hashtag_id = h.id and
    tu.real_name = 'LobbyControl' and
    t.created_at between '2023-01-01' and '2023-01-15'
order by h.txt

```

Table 5.3: A 1.3

txt
ampel
autogipfel
autolobby
bundestag
eu
exxon
exxonknew
korruptionsskandal
lindner
lobbyregister

4.

```

select *
from hashtag h
where h.id in (
    select hp1.hashtag_id
    from hashtag_posting hp1, hashtag_posting hp2
    where hp1.tweet_id = hp2.tweet_id and
    hp1.hashtag_id = hp2.hashtag_id and not
    hp1.pos_start = hp2.pos_start
)

```

Anzahl der Ergebnisse:

Table 5.4: A 1.4 Anzahl der Ergebnisse

count
437

5.

```

select real_name, follower_count
from twitter_user
where created_at <= '2010-01-01'
and follower_count >= all (
    select follower_count
    from twitter_user
    where created_at <= '2010-01-01'
)

```

Table 5.5: A 1.5

real_name	follower_count
Sascha Lobo	761419

5.2 String-Funktionen

1.

```
select txt
from tweet
where txt ilike '%openai%'
and retweet_count >= 20
```

Table 5.6: A 2.1

txt
RT @_SilkeHahn: Guten Morgen: #OpenAI ist doch schon lange #ClosedAI. Seit der ersten Milliarde durch Microsoft 2019 lassen sie sich nicht mehr in die Karten schauen. @netzpolitik_org legt gekonnt den Finger in offene Wunden. Der ``Technical Report'' schweigt sich auf 98 https://t.co/ix1EYCAOKG... https://t.co/hAW5rbRUtH
RT @DrScheuch: Die meisten Aerosolforscher haben damals schon sehr starke Zweifel am Sinn von Ausgangssperren geäußert, (#openairstattausgangssperre) wurden aber nicht gehört. @Karl_Lauterbach, die NoCovid Modellierer und @janoschdahmen waren die lautesten Befürworter. https://t.co/bL7QMaoyKP

2.

```
select txt, char_length(txt) as Laenge
from named_entity
where char_length(txt) >= all (
    select char_length(txt)
    from named_entity
)
```

Table 5.7: A 2.2

txt	laenge
Arbeitsgemeinschaft Sozialdemokratischer Frauen	47

3.

```
select txt
from named_entity
where char_length(txt) >= 4
and txt like reverse(txt)
```


Table 5.8: A 2.3

txt
DAAD
GASAG
CIMIC
ABBA

5.3 Exists-Operatoren

1.

```
select *
from named_entity ne
where not exists (
    select *
    from named_entity_posting nep
    where nep.named_entity_id = ne.id
)
```

Anzahl der Ergebnisse:

Table 5.9: A 3.1 Anzahl der Ergebnisse

count
621

2.

```
select txt
from tweet t
where exists (
    select *
    from hashtag_posting hp, hashtag h
    where hp.hashtag_id = h.id
    and t.id = hp.tweet_id
    and h.txt = 'Klima'
) and exists (
    select *
```

```

from named_entity_posting nep, named_entity ne
where nep.named_entity_id = ne.id
and t.id = nep.tweet_id
and ne.txt = 'Berlin'
)

```

Table 5.10: A 3.2

txt

Erinnerung: Bis 31.01.2023 um 23:59 (Europe/Berlin) könnt ihr noch Themenvorschläge zur #nr23 machen. Z.B. zu #Klima-,#Sozial-,#Sport-,#Medizin-, #Lokal-, #Nonprofit- #Datenjournalismus, #crossborder #Diversität #Pressefreiheit etc.
 Call for Papers: <https://t.co/zyyNCsFC0y> <https://t.co/aDfQOzRG1W>
 RT @DieLinke_HH: Das #Klima retten, nicht den #Kapitalismus! Heute haben wir mit 12.000 anderen in #Hamburg beim #Klimastreik protestiert.

Klare Ansage an Rot/Grün in Hamburg und die Ampel in Berlin: Der Stillstand bei der Klimapolitik muss aufhören! <https://t.co/jbfQrCcQuh> | |So sieht die #Verkehrswende von @spdhh und @GRUENE_Hamburg aus

Frei nach Fairy Ultra: Während in Berlin schon das #9EuroTicket anläuft, werden in #Hamburg noch die Preise erhöht

Soziale #Klimapolitik geht anders!

@9euroforever #Klima @LinksfraktionHH <https://t.co/Fi0eC8km1M> |

3.

```

select tu.twitter_name , tu.real_name
from twitter_user tu
where exists (
  select *
  from tweet t , conversation c
  where t.author_id = tu.id and
  t.id = c.id and
  array_length(c.tweets, 1) >= 70 and
  t.created_at >= '2023-02-15'
)

```

Table 5.11: A 3.3

twitter_name	real_name
salomon_alex	Alexander Salomon
HendrikWuest	Hendrik Wüst

5.4 Aggregat-Funktionen und Gruppierung

1.

```
select ne.id, ne.txt, count(*) as Anzahl
from named_entity ne , named_entity_posting nep
where ne.id = nep.named_entity_id
group by ne.id
order by count(*) desc
```

Anzahl der Ergebnisse:

Table 5.12: A 4.1 Anzahl der Ergebnisse

count
15744

2.

```
select tu.real_name, count(*) as anzahl
from twitter_user tu , tweet t
where tu.id = t.author_id and
tu.typ = 'politician' and
t.created_at > '2022-01-01' and
tu.tweet_count > 2000
group by tu.id
order by anzahl desc
```

Anzahl der Ergebnisse:

Table 5.13: A 4.2 Anzahl der Ergebnisse

anzahl_der_ergebnisse
913

3.

```
with erg(id, anzahl) as (  
  select nep.tweet_id, count(*) anzahl  
  from named_entity_posting nep, tweet t  
  where nep.tweet_id = t.id  
  group by tweet_id  
  having count(*) >= all (  
    select count(*)  
    from named_entity_posting nep  
    group by tweet_id  
  )  
)  
select created_at, txt  
from tweet  
where id in (  
  select id  
  from erg  
)
```

Table 5.14: A 4.3

created_at	txt
2023-01-06 07:50:05	Adrian, Alexander, Ariturel, Björn, Christian, Christian, Christian, Christopher, Cornelia, Danny, Dirk, Frank, Heiko, Johannes, Kai, Katharina, Kurt, Maik, Martin, Michael, Oliver, Robbin, Roman, Sandra, Scott, Stefanie, Stefan, Stephan, Stephan, Sven.

Verdächtig? @cduberlin |

4.

```
select date(created_at), count(*)  
from tweet  
group by date(created_at)
```

```

having date(created_at) > '2022-12-31'
and count(*) >= all (
    select count(*)
    from tweet
    group by date(created_at)
    having date(created_at) > '2022-12-31'
)

```

Table 5.15: A 4.4

date	count
2023-01-25	3568

5.5 Feedback

Punkte: 42.5/43

Zur Aufgabe 1:

1.-5. Richtig

Zur Aufgabe 2:

1.-3. Richtig

Zur Aufgabe 3:

1.-3. Richtig

Zur Aufgabe 4:

1. Richtig 2. Gemeint waren nur Tweets im Datensatz, sonst wäre das
 ↪ etwas einfach (mit HAVING anzahl >2000) =- 0.5 P.

3.-4. Richtig

6 Rekursion, Relationale Algebra und SQL

note: html [Version](#) der Abgabe (fuer die leichtere Kopierung der Code Blocks)

6.1 Data Definition Language (DDL) und Rekursion in SQL

1.

```
create table taxonomy(  
    id int,  
    name varchar,  
    primary key(id),  
    parent int,  
    foreign key (parent) references taxonomy(id)  
);
```

```
insert into taxonomy  
values  
    (0, 'animals', null),  
    (2, 'chordate', 0),  
    (1, 'athropod', 0),  
    (6, 'mammals', 2),  
    (5, 'reptiles', 2),  
    (3, 'insects', 1),  
    (4, 'crustacean', 1),  
    (9, 'carnivora', 6),  
    (8, 'scaled reptiles', 5),  
    (7, 'crocodiles', 5),  
    (10, 'cats', 9),  
    (11, 'pan-serpentes', 8);
```

2.

```

select name
from taxonomy
where parent = 2
union
select name
from taxonomy t1
where exists (
    select name
    from taxonomy t2
    where t1.parent = t2.id
    and t2.parent = 2
)

```

Table 6.1: A 1.2

name
carnivora
reptiles
crocodiles
scaled reptiles
mammals

3.

```

with recursive subCatOfChordate(id, name) as (
    select id, name
    from taxonomy t
    where t.parent = 2
    union
    select t.id, t.name
    from taxonomy t, subCatOfChordate s
    where t.parent = s.id
)
select id
from subcatofchordate

```

Table 6.2: A 1.2

id
6
5
9
8
7
10
11

6.2 Relationale Algebra und SQL

1.

- **rel:** $\pi_{\text{real_name}, \text{tweet_count}, \text{follower_count}} \left(\sigma_{\text{created_at} > 01.01.2019, \text{follower_count} > 8000, \text{tweet_count} > 1000, \text{like_count} > 1000} \left(\beta_{\text{author_id} \leftarrow \text{id}}(\text{twitter_user}) \bowtie \beta_{\text{ca} \leftarrow \text{created_at}}(\text{tweet}) \right) \right)$
- **sql:**

```
select tu.real_name, tu.tweet_count, tu.follower_count
from twitter_user tu
where tu.created_at > '2019-01-01'
and tu.follower_count > 8000
and tu.tweet_count > 1000
and exists (
  select *
  from tweet t
  where t.author_id = tu.id
  and t.like_count > 1000
)
```

Table 6.3: A 2.1

real_name	tweet_count	follower_count
Rote Socke Türk-Nachbaur	16692	21283
Ursula von der Leyen	3675	1295550
Verteidigungsministerium	8923	120387
Carmen Wegge	1029	9355

real_name	tweet_count	follower_count
-----------	-------------	----------------

2.

- **rel:** $\pi_{\text{txt}, \text{author_id}, \text{created_at}}(\sigma_{\text{like_count} > 1000}(\text{tweet}) - \pi_{\text{txt}, \text{author_id}, \text{created_at}}(\sigma_{\text{created_at} > \text{ca}(\sigma_{\text{like_count} > 1000}(\text{tweet}) \times \beta_{\text{ca} \leftarrow \text{created_at}, \text{ai} \leftarrow \text{author_id}, \text{t} \leftarrow \text{txt}}(\sigma_{\text{like_count} > 1000}(\text{tweet}))))))$
- **sql:**

```
select t.txt, t.author_id, t.created_at
from tweet t
where t.like_count >= 1000
and t.created_at <= all (
    select created_at
    from tweet
    where like_count >= 1000
)
```

Table 6.4: A 2.3

txt	author_id	created_at
Die Leute haben heute aus Trotz geböllert, oder? Das nahm ja kein Ende. Genial! Danke.	81497054636662023701	2013-01-01 00:17:32

3.

- **rel:** $\pi_{\text{hi}, \text{hashtag_id}}(\sigma_{\text{ti} < \text{tweet_id}}(\beta_{\text{ti} \leftarrow \text{tweet_id}}(\sigma_{\text{hi} < \text{hashtag_posting}}(\text{hashtag_posting} \bowtie \beta_{\text{hi} \leftarrow \text{hashtag_id}}(\text{hashtag_posting}))) \bowtie \sigma_{\text{hi} < \text{hashtag_posting}}(\text{hashtag_posting} \bowtie \beta_{\text{hi} \leftarrow \text{hashtag_id}}(\text{hashtag_posting}))))))$
- **sql:**

```
with hashtagpairs as (
    select
        hp1.hashtag_id h1_id,
        h1.txt h1_txt,
```

```

        hp2.hashtag_id h2_id,
        h2.txt h2_txt,
        hp1.tweet_id tid
    from hashtag_posting hp1, hashtag_posting hp2, hashtag h1, hashtag
        ↪ h2
    where hp1.tweet_id = hp2.tweet_id
    and h1.id = hp1.hashtag_id
    and h2.id = hp2.hashtag_id
    and hp1.hashtag_id < hp2.hashtag_id
)
select hpr1.h1_txt, hpr1.h2_txt
from hashtagpairs hpr1
where exists (
    select *
    from hashtagpairs hpr2
    where hpr1.h1_id = hpr2.h1_id
    and hpr1.h2_id = hpr2.h2_id
    and hpr1.tid < hpr2.tid
)

```

Table 6.5: A 3.3 Anzahl der Ergebnisse

count
178346

6.3 Regulaere Ausdruecke in SQL

```

select tu.real_name, regexp_count(t.txt, '\m[[:upper:]]{2,}\M') as cnt,
    ↪ t.txt
from tweet t, twitter_user tu
where tu.typ = 'politician'
and t.author_id = tu.id
and regexp_count(t.txt, '\m[[:upper:]]{2,}\M') >= all (
    select regexp_count(txt, '\m[[:upper:]]{2,}\M')
    from tweet
)

```

Table 6.6: A 3

real_name.txt

Udo 41 RT @Georg_Pazderski: BITTE BITTE BITTE BITTE
Hem-
mel-
garn,
MdB

BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE
BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE
BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE BITTE
<https://t.co/snBGvZGABI> |

6.4 Feedback

Punkte: 33/33

Zur Aufgabe 1:

1.-3. Richtig

Zur Aufgabe 2:

1.-3. Richtig

Zur Aufgabe 3:

Geht einfacher, aber richtig.

7 SQL und Abfragesprachen

note: html [Version](#) der Abgabe fuer leichtere Kopierung der Codeblocks.

7.1 Fortgeschrittene SQL-Anfragen

1.

```
select tu.real_name , tu.twitter_name
from twitter_user tu
where tu.typ = 'politician'
and exists (
    select *
    from twitter_user tu2
    where tu2.twitter_name <> tu.twitter_name
    and tu2.real_name = tu.real_name
)
```

Table 7.1: A1.1

real_name	twitter_name
Martin Hagen	_MartinHagen
Martin Hagen	MartinHagenHB

2.

```
select
    tu.real_name real_name,
    tu.twitter_name twitter_name,
    tu.follower_count follower_count,
    tu.tweet_count tweet_count,
    array_length(c.tweets, 1) conversation_length
from tweet t, conversation c, twitter_user tu
where t.id = c.id
```

```

and tu.id = t.author_id
and array_length(c.tweets, 1) >= all (
    select array_length(c2.tweets, 1)
    from conversation c2
)

```

Table 7.2: A1.2

real_name	twitter_name	follower_count	tweet_count	conversation_length
Tom Schreiber	TomSchreiberMdA	5328	48186	86
Christian Lindner	c_lindner	653690	18882	86

3.

```

select ne.txt, ne.id, count(*)
from
    tweet t,
    hashtag_posting hp,
    hashtag h,
    named_entity ne,
    named_entity_posting nep
where t.id = hp.tweet_id
and hp.hashtag_id = h.id
and h.txt ilike 'energie'
and nep.tweet_id = t.id
and nep.named_entity_id = ne.id
group by ne.txt, ne.id
having count(*) >= 4
order by count(*) desc

```

Table 7.3: A1.3

txt	id	count
Deutschland	31	18
Bayern	240	7
Thüringen	526	6
Anschluss	1741	5
Berlin	2	4
Bernhard Stengele	11253	4
CDU	65	4

txt	id	count
Europa	217	4
Bund	655	4

4.

```
select
  ne.id entity_id,
  ne.txt entity_txt,
  date(t.created_at) datum,
  count(*) anzahl
from
  tweet t ,
  named_entity_posting nep ,
  named_entity ne
where t.id = nep.tweet_id
and ne.id =nep.named_entity_id
group by ne.id, ne.txt, date(t.created_at)
order by count(*) desc
limit 5
```

Table 7.4: A1.4

entity_id	entity_txt	datum	anzahl
6	Ukraine	2023-02-24	761
2	Berlin	2023-02-12	427
28	Bundestag	2023-03-17	286
2	Berlin	2023-02-10	283
1425	CSU	2023-03-17	259

7.2 Relationale Algebra und Tupelkalkuel

1.

- **umg**: Was sind die echten Namen von allen Twitter Benutzern, die Lobbyisten sind, die einen Tweet mit ueber 2000 Likes veroeffentlicht haben, der die EU oder die USA erwaeht?
- **tup**:

$$\{\langle \text{tu.real_name} \rangle \mid \text{tu} \in \text{twitter_user} \wedge \text{tu.typ} = \text{'lobby'} \wedge \exists t \exists ne \exists nep ($$

$$\begin{aligned} & t \in \text{tweet} \wedge \\ & ne \in \text{named_entity} \wedge \\ & nep \in \text{named_entity_posting} \wedge \\ & t.\text{id} = nep.\text{tweet_id} \wedge \\ & ne.\text{id} = nep.\text{named_entity_id} \wedge \\ & t.\text{like_count} > 2000 \wedge \\ & t.\text{author_id} = \text{tu.id} \wedge \\ & (ne.\text{txt} = \text{'EU'} \vee ne.\text{txt} = \text{'USA'}) \}) \end{aligned}$$

2.

- **umg:** Was sind die IDs aller Autoren, die zwar einen Tweet mit dem Hashtag ``openai'' verfasst haben aber keinen mit dem Hashtag ``chatgpt''.
- **tup:**

$$\{\langle t.\text{author_id} \rangle \mid t \in \text{tweet} \wedge \exists h \exists hp ($$

$$\begin{aligned} & h \in \text{hashtag} \wedge \\ & hp \in \text{hashtag_posting} \wedge \\ & h.\text{id} = hp.\text{hashtag_id} \wedge \\ & hp.\text{tweet_id} = t.\text{id} \wedge \\ & h.\text{txt} = \text{'openai'} \wedge \\ & \neg \exists h \exists hp (\\ & h \in \text{hashtag} \wedge \\ & hp \in \text{hashtag_posting} \wedge \\ & h.\text{id} = hp.\text{hashtag_id} \wedge \\ & hp.\text{tweet_id} = t.\text{id} \wedge \\ & h.\text{txt} = \text{'chatgpt'}) \}) \end{aligned}$$

7.3 Feedback

Punkte: 28/28

8 Physische Datenorganisation und Baeume

8.1 Seiten und Saetze

1. Satzlaenge twitter_user

Attribute	Typ	Satzlaenge
id	bigint	8 byte
follower_count	integer	4 byte
tweet_count	integer	4 byte
typ	char(11)/char(5) ``politician"/``lobby"	12 byte (1 byte Overhead)
created_at	timestamp	8 byte
twitter_name	text	12 byte
real_name	text	18 byte
---	---	---
Σ		54 byte

2. Speicherplatz der Header

- Jede **Page** hat 24 Byte Header
- Jedes **Tupel** hat 23 Byte Header

D.h. jedes Tupel hat 54 Byte Nutzdaten + 23 Byte Header = 77 Byte.

3. Groesse der Bloecke im PostgreSQL:

```
select current_setting('block_size');
```

Table 8.2: block size

current_setting
8192


```
select count(*)
from twitter_user
```

Table 8.3: Anzahl der Tupel in der Relation twitter user

count
1825

Anzahl der Tupel pro Seite ca.:

```
round(8192 / 77)
```

```
[1] 106
```

Somit ist die Anzahl der Seiten ungefaehr:

```
round(1825 / 106)
```

```
[1] 17
```

4. Anzahl der Seiten der Relation `twitter_user`:

```
select relname, relpages
from pg_class
where relname = 'twitter_user'
```

Table 8.4: Anzahl der Seiten fuer twitter user

relname	relpages
twitter_user	22

Also in Wirklichkeit werden 22 Seiten gebraucht statt 17 Seiten. D.h. mehr Speicher. Die Gruende dieser Abweichung sind u.a. mehr Speicher fuer:

- Pageheader
- Zeiger auf die Tupel
- Special-/Free Space in Pages
- Optionalen Zusatzelementen wie Null Bitmap in den Tuples

8.2 B-Baeume

1. B-Baum 1.1 Figure 8.1




Figure 8.1: B-Baum: A2.1

2. B-Baum 1.2 Figure 8.2

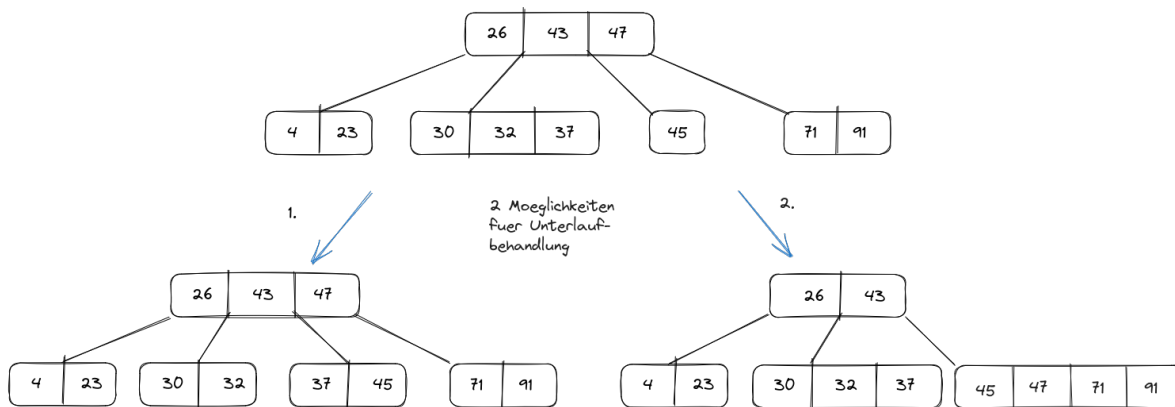


Figure 8.2: B-Baum: A2.1

8.3 B⁺-Baeume

1. B⁺-Baum 3.1 Figure 8.3

2. Die Elemente in der sortierten Reihenfolge in den B⁺ Baum einfügen, aber nicht durch ein normales Insert, sondern direkt an das Blatt ganz rechts einfügen. Dadurch spart man sich die look-up Operation $\mathcal{O}(\log_m(n))$ des insert, die ein groeseres Element als die bisherigen sowieso ganz rechts in Baum ablegen wuerde.




Figure 8.3: B-Baum: A2.1

8.4 Feedback

Punkte: 19.5/24.0

- A1: 5.0/8.0
- A2: 6.5/8.0
- A3: 8.0/8.0

Zur Aufgabe 1:

1. typ hat Länge 4, da enum => -0.5 P.
2. Tupel Header richtig, Attribut-Größe fehlt => -0.5 P.
3. So war die Aufgabe nicht gemeint, man sollte aus den Werten der 1. und 2. das Ausrechnen => -2 P.
4. Richtig

Zur Aufgabe 2:

1. Richtig 2. Beide Varianten nicht ganz richtig:

Grundstruktur teilweise richtig: Links sehr nah an ML man müsste nur 43 und 37 tauschen (der angesprochene Leichtsinnsfehler), rechts bei Löschen eines Nicht-Blattknotens wird Element durch (längen-)lexikographisch nächst kleineres Element ersetzt, in diesem Fall die 47. Ab dann ändert sich logischerweise auch euer Baum im Vergleich zur ML.

=> -1.5 P.

Zur Aufgabe 3:

1. Diese Woche war die ML falsch, deswegen habe ich hier einen Fehler
↪ beim Korrigieren gemacht. Nur Ma zu M wäre schön.
2. Habe ich übersehen, ist richtig.

9 Hashing, Indexzugriffe und Sortierung

9.1 Erweiterbares Hashing

1. Einfuegen der Woerter des Limerick

a.

h	bucket
00	Who, feared
10	Man, said
01	beard
11	Old

b.

h	bucket
000	hen, four
001	who, feared
10*	man, said
010	beard, built
011	owls, wren
110	larks, nests
111	old, two

2. Loeschen der Woerter

h	bucket
000	hen, four
001	who, feared
10*	man, said
010	built
011	wren
110	larks

h	bucket
111	---

Der Bucket fuer 111 ist leer und 010 bis 110 sind nur halbvoll. Somit wird die Speicherzelle vom Bucket 111 unnötig reserviert / blockiert, und die Tabelle ist unausgeglichen

Eine Lösung wäre ``Buckets zu verkleinern'' also zwei Buckets der lokalen tiefe t zu einem bucket der tiefe $t-1$ zusammenzufassen, wenn ``zu wenig'' Elemente dort enthalten sind bzw. die Buckets leer sind.

Ein Vorteil hiervon wäre eine höhere Speichereffizienz. Ein Nachteil der erhöhte Aufwand durch prüfen der Füllmenge, mehr Kopieren, etc. Ausserdem könnte es zu vielen Kopieroperationen kommen, bei ungünstigen Einfüge-/Löschooperationen. (Wiederholtes löschen & einfügen auf **einen** Bucket).

9.2 Sortierung

a. 25.000 Blöcke, 48 Blöcke im HS

1. $\frac{25000}{48} \approx 521$
2. $\lceil \log_{47}(521) \rceil \approx 1,625 \approx 2$
3. $2 \cdot 25000 \cdot (1 + 2) = 150000$
4. passt bereits.

b. 24.000.000 Blöcke Relation, 64 Blöcke im HS

1. Anzahl der Partitionen: $\frac{24000000}{64} = 375000$
2. $\lceil \log_{63} 375000 \rceil = 4$
- 3.

$$\begin{aligned} 2 \cdot 24.000.000 \cdot (1 + \lceil \log_{63} 375000 \rceil) &= 2 \cdot 24.000.000 \cdot (1 + 4) \\ &= 5 \cdot 2 \cdot 24.000.000 \\ &= 240.000.000 \end{aligned}$$

4.

$$\begin{aligned} \log_x \frac{24 \cdot 10^6}{x} = 2 &\iff x^2 = \frac{24 \cdot 10^6}{x} \\ x^3 &= 24 \cdot 10^6 && (\text{Mult } x) \\ x &= \sqrt[3]{24 \cdot 10^6} && (\sqrt[3]{\bullet}) \\ x &\approx 289 \end{aligned}$$

9.3 Zugriffsmethoden

1. b) ist effizienter. Nur Tupel mit $d \in [0, 500)$ kommen fuer die Ergebnisrelation in Frage. Dies lässt sich schnell mit B^+ -Baum ausgeben, schneller als 7,8 Mill. Tupel zu scannen.
2. a) ist effektiver, denn es werden auf jeden Fall alle Elemente ausgegeben ausser $d = 1000000$. Fuer dieses muss gepreuft werden ob $y > 42 \wedge y < 50$. Aber weil eh so gut wie alle Elemente ausgegeben werden macht Index-zugriff keinen Sinn.
3. Gesucht sind mindestens alle Tupel t mit $d \in [7100000, 7150000)$. Dies lässt sich gut mit B^+ -Baum abfragen. Deshalb b).
4. Hier lohnt es sich wieder mit dem B^+ -Baum eine Vorauswahl an Elementen zu machen, da $d \in I_1[0, 100] \vee d \in I_2[8800, 9000) \vee d \in I_3[7000000, 7001000)$ ein wesentlich kleinerer Wertebereich ist als die komplette Relation.

9.4 Feedback

Punkte 24.0/28.0

- A1: 10.0/10.0
- A2: 8.0/10.0
- A3: 6.0/10.0

Zur Aufgabe 1:

1.-2. Richtig

Zur Aufgabe 2:

1. Richtig 2. Richtig 3. Richtig 4. a) Trotzdem solltet ihr ausrechnen,
↪ wie viele Blöcke benötigt werden b) Es wird noch ein weiterer Block
↪ zum Sortieren benötigt => -2 P.

Zur Aufgabe 3:

1. Falsch, da Tupel bereits sortiert sind => -2 P. 2. Richtig 3. Richtig
↪ 4. Richtig

10 Anfragebearbeitung

10.1 Join-Strategien

1. cost: $b_r + \lceil \frac{b_r}{\text{mem}-1} \rceil \times b_s$
R: 115000 Tupel, 30 pro Seite \Rightarrow 3834 Seiten
S: 22500 Tupel, 100 pro Seite \Rightarrow 225 Seiten
mem = 70

$$\text{Somit: cost} = 225 + \lceil \frac{225}{69} \rceil \times 3834 = 15561$$

Kosten sind minimal g.d.w. b_r Komplet in dem Speicher passt und noch eine Seite frei ist fuer $b_s \Rightarrow 226$:

$$\text{cost} = 225 + \lceil \frac{225}{226-1} \rceil \cdot 3834 = 4059$$

2. cost: $b_r + p \cdot b_s$ mit $p = \lceil \frac{b_r}{\text{mem}-1} \rceil$
 \Rightarrow Kosten gleich wie Block-Nested-Loop.
3. Da die Formeln zu Berechnung gleich sind, sind beide Algorithmen gleich optimal bei einer RAM-Groesse von 226 Sieten. (Kosten wie in 1.)
4. Y ist primary-key von S \Rightarrow alle Werte sind Unique. D.h. ein tupel in R kann mit max **einem** Tupel aus S matchen **aber** ein Tupel aus S kann maximal mit allen Tupel aus R matchen.

D.h. maximal: 115000 Tupel wenn alle aus R matchen.

R: 30 Tupel Pro Seite,

S: 100 Tupel pro Seite,

S + R = ?

$$\begin{aligned}
r &\in R, s \in S, p := \text{Seite} \\
30r = p &\Leftrightarrow r = \frac{1}{30}p \\
100s = p &\Leftrightarrow s = \frac{1}{100}p \\
x(s + r) &= p \\
\Rightarrow x\left(\frac{1}{30}p + \frac{1}{100}p\right) &= p \\
\Leftrightarrow x \frac{13p}{300} &= p \\
\Leftrightarrow x \approx 23,07 \approx 23 \text{Tupel} & \quad (\text{Annahme: nicht-Spannsaetze})
\end{aligned}$$

Somit: $\frac{115000 \text{ Tupel}}{23 \frac{\text{Tupel}}{\text{Seite}}} = 5000 \text{ Seiten}$

10.2 Algebraische Optimierung

```

1. select tu.real_name, tw.txt
   from
       tweet tw,
       named_entity ne,
       named_entity_posting nep,
       twitter_user tu
   where tw.author_id = tu.id
         and nep.tweet_id = tw.id
         and nep.named_entity_id = ne.id
         and tw.created_at > '2022-04-15'
         and tw.like_count > 6000
         and ne.txt like 'Berlin'
         and tu.created_at < '2015-01-01'

```

Table 10.1: A2.1

real_name

Sahra Das Manifest für Frieden hat jetzt schon eine Viertelmillion Unterstützer:
 Wa- <https://t.co/uC3H0FBZix> Druck von unten kann etwas bewirken! Lasst uns den
 genknecht Protest gegen #Waffenlieferungen und für #Frieden und #Diplomatie nun auch die
 Straße tragen: Am 25. Februar um 14 Uhr in Berlin

real_nam

HermanGemeinsam haben wir heute fraktionsübergreifend als politische Patinnen und Paten
Gröhe von Opfern und Verfolgten des iranischen Regimes vor der iranischen Botschaft in
Berlin protestiert. Wir sehen die Verbrechen des iranischen Regime!

#IranRevoLution #JinJiyanAzadi #Iran <https://t.co/rDZC6KpBA2>

Sahra Großartig: Eine halbe Million Unterschriften für das #ManifestfuerFrieden nach
Wa- einer Woche! Herzlichen Dank & gerne weiter verbreiten: <https://t.co/uC3H0FBZix>
genknechtUnd kommt zur #Friedenskundgebung am 25.02. um 14 Uhr vor dem Brandenburger
Tor in Berlin! <https://t.co/2jxKTNGNpH> <https://t.co/WWXWoV9NID>

Sahra Ein Jahr #Krieg ist mehr als genug! Es braucht Druck von unten für
Wa- #Verhandlungen. Jeder verlorene Tag kostet weitere Menschenleben und bringt uns
genknechtinm 3. Weltkrieg näher. Deshalb: Kommt am 25. Februar um 14 Uhr zur großen
#Friedenskundgebung nach Berlin: <https://t.co/2jxKTNGNpH>
<https://t.co/yu5vc30uv1>

Sahra Nicht alle Ukrainer ziehen mit Begeisterung an die Front, und wer zu
Wa- #Verhandlungen aufruft, fordert keine Kapitulation. In der Berliner Zeitung
genknechtbegründe ich, warum wir morgen um 14 Uhr in Berlin ein Stoppzeichen gegen
weitere Kriegs-#Eskalation

setzen.

<https://t.co/OblSye7pJ6>

Sahra Auf geht's zur großen Kundgebung ``Aufstand für den Frieden'' am BRB Tor in
Wa- Berlin - mit Reden von Alice Schwarzer, Brigade-General a.D. Erich Vad, Jeffrey
genknechtSachs, mir und Weiteren. Für jene, die nicht vor Ort sein können startet (hier) 14:00
ein Livestream: <https://t.co/lNpFdi6sv7>

Sevim 50.000 Menschen auf der #Friedenskundgebung #AufstandFuerFrieden in Berlin am
Dağde- Brandenburger Tor!

len,

MdB

#b2502

<https://t.co/lB5NZYruWX>

Sahra Heute kamen mehr als 50000 Menschen zu unserer Friedensdemo nach Berlin. Wir
Wa- sind viele, das hat die Veranstaltung gezeigt. Ein herzliches Dankeschön an alle, die
genknecht dabei waren!

Sahra Schätzungsweise 50.000 Menschen nahmen gestern an unserer Friedenskundgebung
Wa- am Brandenburger Tor in Berlin teil. Dazu haben Alice Schwarzer & ich eine
genknechtErklärung veröffentlicht: <https://t.co/gBbEHxgS8Q>

2.

$$\pi_{tu.real_name, tw.txt} \left(\begin{aligned} &\sigma_{\begin{aligned} &nep.tweet_id = tw.id \wedge tw.author_id = tu.id \wedge \\ &nep.named_entity_id = ne.id \wedge tw.created_at > '15.04.2022' \wedge \\ &tw.like_count > 6000 \wedge ne.txt \text{ like } 'Berlin' \\ &tu.created_at < '01.01.2015' \end{aligned}} \\ &\left(\beta_{tw}(tweet) \times \beta_{ne}(named_entity) \right. \\ &\quad \left. \times \beta_{nep}(named_entity_posting \times \beta_{tu}(twitter_user)) \right) \end{aligned} \right)$$

3. Siehe Figure 10.1

4. Siehe Figure 10.2




Figure 10.1: A2.3: nicht optimiert


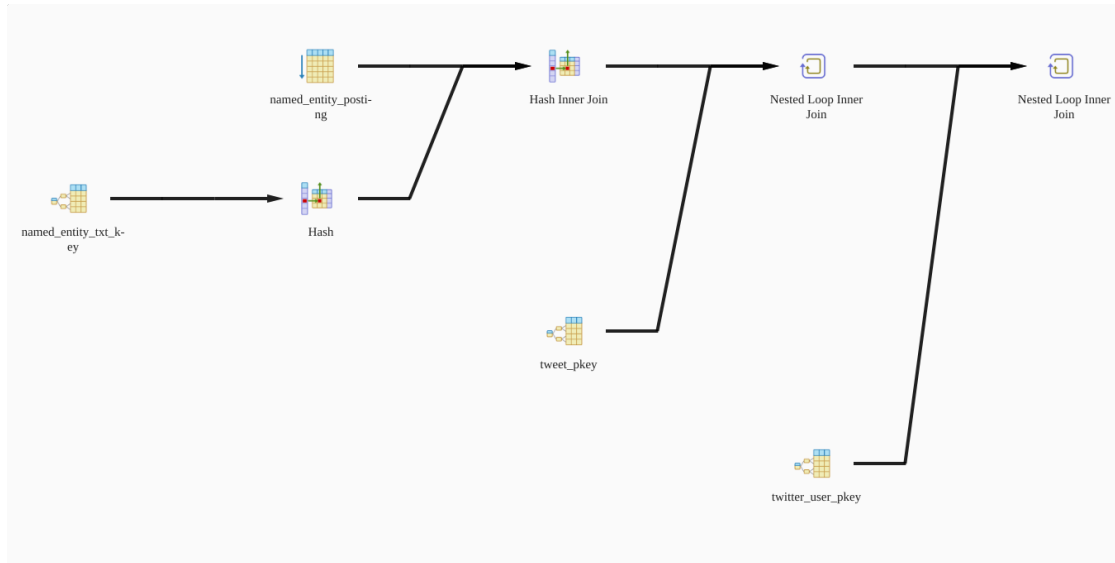


Figure 10.2: A2.4: optimiert

5. Operatorbaum mit pgadmin explain ?@fig-a2-5



Der Operatorbaum i.A. ähnlich zu dem Operatorbaum aus 4), in dem Sinne das 1. Die Selektionen ebenfalls nach unten geschoben wurden und immer **vor** den join-Operationen stehen. Denn wir haben hier ausserdem keine Kreuzprodukte, sondern 2. alle Kreuzprodukte wurden durch joins ersetzt.

Spannend ist ausserdem, dass hier ein richtiger Anfrageplan vorliegt, da joins/scans genau definiert wurden (index-scan, hash inner join, ...).

Darueber hinaus ist die join Reihenfolge anders: Da die Selektion ueber der Relation **named_entity** nur ein Ergebnis liefert, steht diese ganz unten und haelt alle Folgeergebnisse schlank. (Alle joins machen nur einen loop. Steht wenn man auf die joins klickt)

10.3 Feedback

Punkte: 18.0/23.0

- A1: 7.0/11.0
- A2: 11.0/12.0

Rose, Dimitrov, Barthelmes

Aufgabe 1:

3. Naja, es wird ja nicht nach dem optimalen Algorithmus *aus 1 oder 2*
 ↳ gefragt, sondern nach dem optimalen Algorithmus überhaupt
4. Falsche Formeln, falsches Ergebnis

7/11 Punkte

Aufgabe 2:

wo textdatei

3. Es fehlen die Projektionen nach den notwendigen Attributen

10/12 Punkte

Insgesamt 17/23 Punkte

Part II

Notes